

Sparse Matrix Transposition for GPUs

Massimiliano Incudini - VR433300

Michele Penzo - VR439232

Sommario—L'obiettivo principale di questo progetto è stato quello di implementare alcune metodologie proposte per effettuare *Sparse Matrix Transposition* su *Gpu*. Sono stati analizzati alcuni algoritmi, descritti in sezione IV, partendo dall'algoritmo seriale, passando a *cuSPARSE* per finire con l'implementazione degli algoritmi descritti in [1]. Infine vengono esposti i risultati e tratte le conclusioni.

I. INTRODUZIONE

Sempre più applicazioni computazionali in ambito scientifico necessitano di algoritmi che compiano operazioni che si possano applicare su matrici sparse. Si parla di semplici operazioni di algebra lineare, di moltiplicazione o di calcolo della trasposta come nel nostro caso.

Il problema analizzato, quello della trasposizione di matrici, si presta bene al calcolo parallelo per aumentarne l'efficienza. Verranno quindi mostrate le basi per la rappresentazione ed analizzati alcuni algoritmi per il calcolo su *Gpu*.

II. RAPPRESENTAZIONE DELLE MATRICI

Viene detta matrice sparsa una matrice in cui i valori sono quasi tutti uguali a zero. Per rappresentare in modo efficace, senza troppi sprechi di memoria, sono state introdotte varie forme di rappresentazione matriciale. La struttura dati classica utilizza una quantità di memoria minima di $m \times n$ elementi. Sono state quindi utilizzate delle rappresentazioni che permettono il salvataggio di dati utilizzando quantitativi di memoria inferiori.

A. Csr

Il *compressed sparse row* è una rappresentazione di una matrice M basata su tre array monodimensionali, che rispettivamente contengono:

- 1) V : i valori nnz ,
- 2) COL_INDEX : gli indici delle colonne dove si trovano gli elementi nnz ,
- 3) ROW_INDEX : rappresenta l'indice in V dove la riga comincia

I primi due array sono di dimensione nnz , mentre il terzo array è al massimo di dimensione M .

B. Csc

Questa metodologia per la rappresentazione è simile alla sopra citata *Csr*, solo che i valori vengono letti prima per colonna. Di conseguenza, un indice di riga viene memorizzato per ogni valore e i puntatori di colonna vengono memorizzati.

III. STRUTTURA DELL'IMPLEMENTAZIONE

IV. METODOLOGIE ANALIZZATE

In questa sezione vengono spiegate ed evidenziate le differenze tra le varie metodologie analizzate.

A. Trasposta seriale

La prima metodologia descritta è quella seriale. Sempre a partire dalla rappresentazione in formato *csr* della matrice iniziale l'algoritmo crea un array di elementi, dove per ogni colonna della matrice analizzata conta quanti elementi **nnz** ci sono. Possiamo definire questo array come un istogramma delle frequenze degli elementi delle colonne. Viene quindi applicato un algoritmo seriale di *prefix_sum* su questo array, che conterrà ora i valori corretti di **cscColPtr**. Infine gli indici di riga e i valori nel nuovo formato *csc* vengono sistemati. Questa implementazione servirà come base sulla quale verranno eseguiti i controlli degli algoritmi successivamente implementati.

B. Nvidia cuSPARSE

Questo toolkit è implementato all'interno nelle librerie NVIDIA CUDA runtime. Le routine delle librerie vengono utilizzate per le operazioni tra vettori e matrici che sono rappresentate tramite diversi formati. Inoltre mette a disposizione operazioni che permettono la conversione attraverso diverse rappresentazioni di matrici, ed inoltre la compressione in formato *csr* che è una delle più usate quando si vuole rappresentare matrici sparse in modo efficiente.

Il codice è stato sviluppato basandosi su due versioni di *cuSPARSE* a causa delle *Gpu* utilizzate. In fase di compilazione viene quindi controllata la versione usata: 9 o 10.

Nel caso in cui la versione usata sia la 10 vengono svolti alcuni ulteriori passi, viene effettuata l'allocazione dello spazio necessario e del buffer per il calcolo della trasposta. Per quanto riguarda la versione 9 invece questi passi non sono necessari. Infine viene chiamata la procedura che effettua il calcolo della trasposta.

Le procedure chiamate sono diverse in base alla funzione. Nel primo caso viene chiamata **cusparsescsr2csc**, mentre nel secondo caso **cusparsescsr2cscEx2**. Quest'ultima richiede come parametro anche l'algoritmo che viene utilizzato all'interno della procedura.

Dopo essere state eseguite entrambe ritornano i valori ottenuti tramite un'altro formato, *csc*, che ne esprime la rappresentazione tramite valori come *csrColIdx*, *cscVal*, *cscColPtr*, *cscRowIdx*. Infine viene controllata la correttezza e i tempi rispetto alle altre implementazioni.

C. ScanTrans

D. MergeTrans

V. ESPERIMENTI

VI. RISULTATI

VII. CONCLUSIONI

RIFERIMENTI BIBLIOGRAFICI

- [1] K. H. W.-C. F. Hao Wang, Weifeng Liu, "Parallel transposition of sparse data structures," *ICS '16*, 2016.